Predikcija nivoa rizika ponovne hospitalizacije pacijenta

Irina Radanović, IN 5/2022, irinaradanovic95@gmail.com
Nikolina Brkljač, IN 2/2022, nikolina.brkljac03@gmail.com

I. Uvod

Rehospitalizacija pacijenata u kratkom vremenskom periodu nakon otpusta predstavlja jedan od ključnih izazova savremenih zdravstvenih sistema, ne samo zbog značajnih finansijskih troškova, već i kao indikator kvaliteta pružene medicinske nege. Cilj ovog rada je razvoj i evaluacija modela klasifikacije koji, na osnovu demografskih, kliničkih i laboratorijskih parametara, vrši predikciju rizika od ponovnog prijema u bolnicu.

II. Baza podataka

Baza podataka koja je korišćena je javno dostupna baza "Hospital Readmission Risk dataset" , koja obuhvata podatke o 10000 pacijenata. Svaki uzorak u bazi opisan je sa 23 obeležja koja se sastoje od demografskih, kliničkih i životnih karakteristika pacijenta.

Pregled svih obeležja:

- patient_id : jedinstveni identifikator pacijenta
- age : numeričko - starost pacijenta
- gender : kategoričko - pol pacijenta(muško/ženski)
- weight_kg : numeričko - telesna težina izražena u kilogramima
- height_cm : numeričko - visina izražena u centimetrima
- bmi : numeričko - indeks telesne mase
- num_previous_admissions : numeričko - broj prethodnih prijema
- chronic_conditions : kategoričko - hronična stanja(nijedno/hronična opstruktivna bolest pluća/ dijabetes/ visok krvni pritisak/srčana bolest)
- medications_count : numeričko - broj lekova koje uzima
- last_hemoglobin : numeričko - poslednji izmereni hemoglobin
- last_hemoglobin : numeričko - poslednji izmereni hemoglobin
- last_glucose : numeričko - poslednja izmerena glukoza
- last_creatinine : numeričko - poslednje izmeren kreatinin
- admission_type : kategoričko - tip prijema(hitni/urgentni/planirani)
- length_of_stay : numeričko - dužina boravka u danima
- procedures_count : numeričko - broj zahvata tokom boravka
- smoking_status : kategoričko - da li je pušač(nikad/bivši/sadašnji)
- alcohol_use : kategoričko - da li konzumira alkohol(nikad/srednje/visoko)
- physical_activity: kategoričko - nivo fizičke aktivnosti (nisko/srednje/visoko)
- insurance_type : kategoričko - tip osiguranja(privatno/javno/neosiguran)
- followup_compliance : kategoričko - ispoštovanje terapije nakon otpusta(dobro/loše)
- social_support : kategoričko - socijalna podrška(jaka/slaba)
- mental_health_issue : kategoričko - problemi sa mentalnim zdravljem(da/ne)
- readmission_risk : kategoričko - rizik od ponovnog prijema(nizak/srednji/visok)

U ovom projektu, obeležje "readmission_risk" predstavlja ciljnu promenljivu, rešava se klasifikacioni problem sa tri klase. Analizom, utvrđeno je da je baza balansirana, pri čemu svaka klasa zauzima približno trećinu ukupnog broja uzoraka.

III. Metodologija istraživanja

Proces razvoja modela podeljen je u tri faze: istraživačku analizu, čišćenje i transformaciju podataka, čime je osigurana maksimalna informativnost atributa pre same faze obučavanja algoritama.

A. *Istraživačka Analiza Podataka (EDA)*

Primarni cilj EDA faze bio je ispitivanje distribucije obeležja i identifikacija potencijalnih nepravilnosti u podacima.

Proverom balansa klasa utvrđeno je da su klase ciljne promenljive uniformno raspoređene.

Detaljnom analizom distribucija numeričkih obeležja (Sl. 1.) uočeno je da su klase ciljne promenljive uniformno raspoređene kroz ceo opseg vrednosti svih atributa, uključujući laboratorijske nalaze poput glukoze i kreatinina. Proporcija pacijenata sa visokim, srednjim i niskim rizikom ostaje gotovo nepromenjena bez obzira na varijaciju kliničkih parametara. Slično, vizuelizacijom kategoričkih atributa uočeno je da su nivoi rizika takođe ravnomerno zastupljeni unutar svake kategorije. Ovakva struktura ukazuje na to da podaci verovatno potiču iz

sintetičkog generatora, gde su zavisnosti između atributa suptilne. Ovo predstavlja fundamentalno ograničenje za bilo koji algoritam klasifikacije

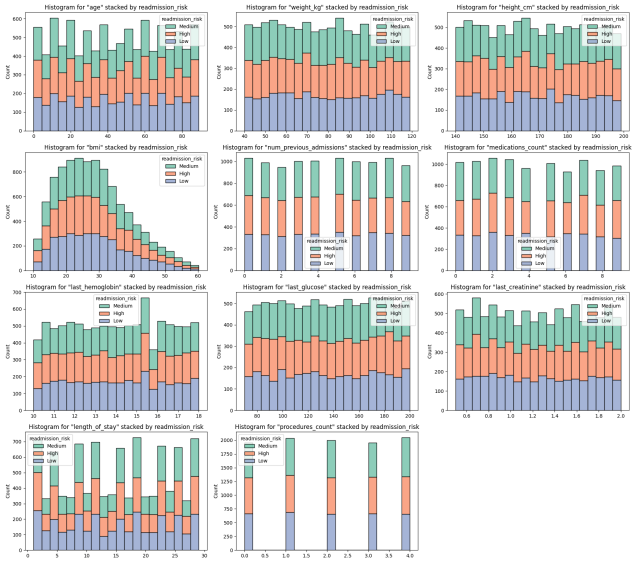

Sl. 1. Distribucija numeričkih obeležja po klasama rizika (Histogrami)

Vizuelizacijom pomoću *boxplot* dijagrama (Sl. 2) identifikovana je grupa pacijenata sa ekstremno visokim *bmi* vrednostima, koje se kreću od 57 pa sve do 60.

Iako ove vrednosti značajno odstupaju od proseka ostatka baze, doneta je odluka da se oni ne uklanjaju jer i dalje predstavljaju realan medicinski podatak. Dodatnom analizom utvrđeno je da ovi ekstremni pacijenti nisu nužno svi u grupi visokog rizika (Sl. 3).

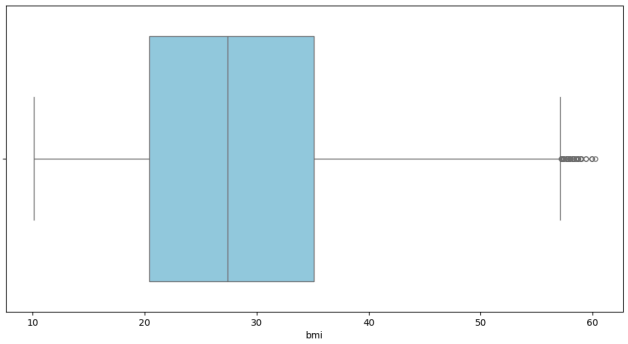

Sl. 2. Boxplot distribucija *BMI* indeksa

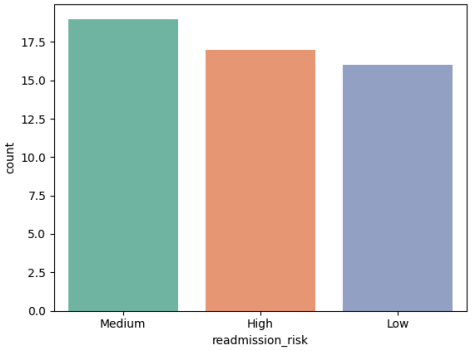

Sl. 3. Distribucija ciljne promenljive unutar podskupa *BMI* autlajera

Korišćenjem korelacione matrice (Sl. 4) ispitane su linearne zavisnosti između numeričkih atributa. Najznačajnija korelacija uočena je između visine, težine i BMI indeksa. Budući da je BMI izvedena veličina (BMI = težina/visina^2), zadržavanje sva tri parametra uvelo bi problem multikolinearnosti.

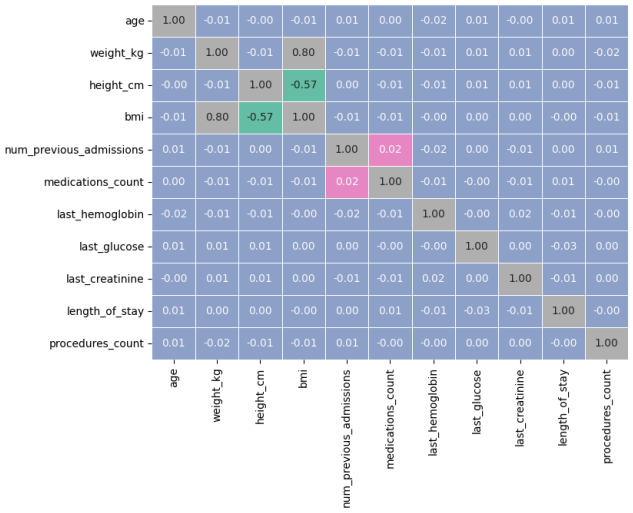

Sl. 4. Korelaciona matrica obeležja

B. Priprema i čišćenje podataka

Inicijalna provera ukazala je na prisustvo *NaN* vrednosti u kolonama *chronic_conditions* i *alcohol_use*. Detaljnom analizom utvrđeno je da ove vrednosti nisu slučajni propusti, već predstavljaju pacijente bez hroničnih bolesti, odnosno one koji ne konzumiraju alkohol. Shodno tome, ove vrednosti su tretirane kao posebna kategorija "None", čime je sačuvan integritet kliničke slike pacijenta.

Dalje u pripremi podataka je izvršena selekcija obeležja. Na osnovu rezultata korelacione matrice, iz daljeg procesa isključeni su atributi *weight_kg* i *height_cm*, dok je *bmi* zadržan kao sumarna metrika telesne konstitucije. Takođe, uklonjen je *patient_id* jer predstavlja jedinstveni identifikator koji ne nosi nikakvu prediktivnu vrednost.

C. Finalna priprema i transformacija podataka

Pre ulaska u modele mašinskog učenja, podaci su transformisani u numerički format pogodan za matematičke operacije.

Strategije enkodiranja**:** Primenjena su tri različita pristupa u zavisnosti od prirode podataka:.

- Ordinalno enkodiranje: Za atribute sa logičkim redosledom (npr. *physical_activity*) korišćeno je ručno mapiranje u celobrojne vrednosti. Ovo omogućava modelu da prepozna intenzitet obeležja.
- One-Hot enkodiranje: Za nominalne atribute bez prirodnog poretka (npr. *gender*) korišćena je tehnika *dummy* varijabli. Ovim se sprečava da model pogrešno interpretira numeričke vrednosti kao nivoe prioriteta.
- Label Encoding: Primenjen je na ciljnu promenljivu (*readmission_risk*) zato što algoritmi mašinskog učenja zahtevaju numeričke labele. Ovim postupkom su tekstualne kategorije rizika

mapirane u celobrojne vrednosti prema abecednom redosledu, što je rezultovalo sledećim kodiranjem:

- 0 : High (Visok rizik)
- 1 : Low (Nizak rizik)
- 2 : Medium (Srednji rizik)

Skup podataka podeljen je na trening (90%) i test deo (10%) uz primenu stratifikacije, čime je garantovana ista proporcija klasa u oba podskupa. Finalni korak obuhvatio je standardizaciju numeričkih obeležja (*StandardScaler*). Svođenje svih atributa na istu skalu (prosek 0, varijansa 1) je esencijalno za algoritme poput kNN-a koji se oslanjaju na Euklidsku distancu, jer sprečava da atributi sa većim apsolutnim vrednostima (npr. godine) dominiraju nad onima sa manjim vrednostima (npr. kreatinin).

Kako bi se ispitala separabilnost klasa, primenjena je Analiza glavnih komponenti (PCA). S obzirom na to da je prostor obeležja višedimenzionalan i nemoguć za direktnu vizualizaciju, podaci su projektovani u 2D ravan (Sl. 5.).

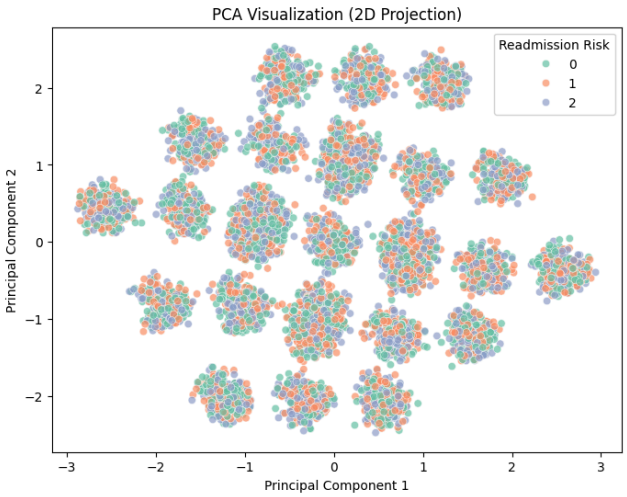

Sl. 5. 2D projekcija skupa podataka pomoću *PCA* metode

Primećuje se potpuno odsustvo jasnih granica između tri nivoa rizika. Tačke različitih boja su uniformno raspoređene u istom prostoru. Formiranje izolovanih klastera je posledica prisustva kategoričkih obeležja koja grupišu slične profile pacijenata. Međutim, unutar svakog klastera i dalje su prisutne sve tri klase podjednako.

IV. RAZVOJ MODELA I REZULTATI

U cilju predikcije nivoa rizika ponovne hospitalizacije, evaluirano je više modela mašinskog učenja: logistička regresija, k-najbližih suseda (kNN), stablo odluke i *random forest*. Proces obučavanja postavljen je kroz tri različita pristupa pripremi podataka, korišćenje originalnih obeležja, primenu PCA transformacije i primenu LDA metode za maksimizaciju razdvajanja klasa.

Važno je istaći da su transformacije podataka korišćene selektivno, u skladu sa prirodom algoritama. Logistička regresija i kNN su testirani na redukovanim komponentama jer ovi modeli najbolje rade kada se ukloni šum i kada se prostor linearno transformiše. Primenom PCA sa ciljem očuvanja 95% varijanse, broj obeležja je smanjen sa 25 na 22. Dok je LDA (Linearna diskriminantna analiza) projektovala podatke u dvodimenzionalni prostor.

Sa druge strane, stabla odlučivanja i *Random Forest* su obučavani samo na originalnim obeležjima. Ovi modeli su po svojoj prirodi nelinearni, pretvaranje originalnih obeležja u apstraktne PCA ili LDA komponente kod njih često dovodi do gubitka interpretabilnosti, jer stabla sama vrše selekciju bitnih atributa tokom procesa grananja.

Za svaki model izvršena je optimizacija hiperparametara pomoću *GridSearchCV* metode uz petostruku unakrsnu validaciju. Ovakav pristup osigurao je da modeli budu testirani na različitim podskupovima podataka uz očuvanje balansa klasa.

Upravo je logistička regresija u kombinaciji sa LDA transformacijom ostvarila blagu prednost tokom unakrsne validacije sa F1-merom od 0.3583. Iako su razlike u odnosu na ostale modele minimalne, ovaj model je izabran kao osnovni.

Rezultati pokazuju da logistička regresija postiže tačnost od približno 0.34, dok su preciznost, odziv i F1-mera (makro prosek) takođe oko 0.34. S obzirom na to da problem uključuje tri klase, slučajan klasifikator bi imao očekivanu tačnost od oko 0.33, što ukazuje da model ostvaruje performanse tek neznatno bolje od nasumičnog pogađanja.

Detaljnija analiza klasifikacionog izveštaja pokazuje da su sve tri klase približno jednako tretirane od strane modela. Klasa niskog rizika ima blago veći odziv (0.38), dok klasa srednjeg rizika pokazuje nešto slabije rezultate (0.31). Ne postoji izražena pristrasnost ka određenoj klasi, ali ni jasna sposobnost modela da ih razdvoji.

Matrica konfuzije(Sl. 6.) dodatno potvrđuje ove nalaze. Prisutan je visok nivo mešanja između svih klasa, bez izražene dominacije elemenata na glavnoj dijagonali. Model pokazuje blagu tendenciju ka češćem predviđanju niskog nivoa rizika, ali su greške raspoređene kroz sve klase, što ukazuje na nedostatak jasnih granica između njih.

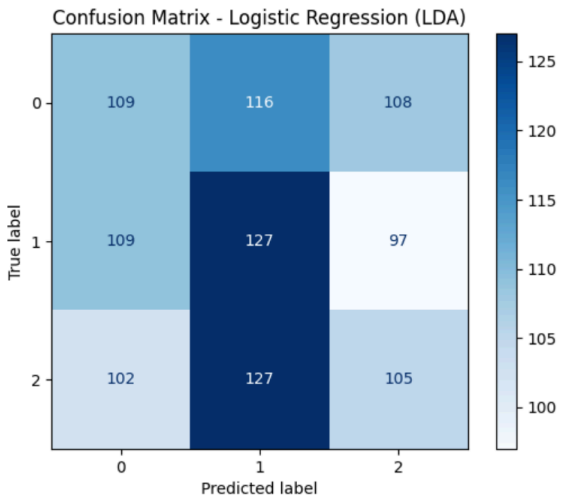

Sl. 6. Matrica konfuzije Logističke regresije

Nakon odabira najboljih varijanti svakog modela, izvršena je finalna evaluacija na testnom skupu podataka**.** Uporedna evaluacija svih modela pokazuje vrlo slične performanse(Tabela 1). Sve metode ostvaruju rezultate u opsegu od 0.32 do 0.34 za sve posmatrane metrike. Logistička regresija sa LDA transformacijom postiže blago najbolje rezultate (F1 ≈ 0.34), dok kNN, stablo odluke i *random forest* imaju približno 0.32. Razlike između modela su minimalne i statistički zanemarljive.

Model	Accuracy	Precision	Recall	F1_macro	F1_weighted
Logist. regresija (LDA)	0.3410	0.3409	0.3410	0.3404	0.3404
KNN(PCA)	0.3240	0.3221	0.3239	0.3225	0.3225
Stablo odluke	0.3230	0.3228	0.3230	0.3228	0.3228
Random Forest	0.3230	0.3229	0.3230	0.3224	0.3224

Tabela 1. Komparativna analiza performansi modela na testnom skupu

Zanimljivo je da kompleksniji modeli, poput *random forest*-a, nisu doneli poboljšanje u odnosu na jednostavniji linearni model. Takođe, kNN, koji se oslanja na metriku rastojanja, nije uspeo da iskoristi strukturu podataka za bolju separaciju klasa. Ovi rezultati ukazuju da povećanje kompleksnosti modela ne doprinosi boljoj generalizaciji.

Ovakvo ponašanje modela u skladu je sa prethodnom analizom podataka. PCA vizualizacija je pokazala značajno preklapanje klasa u prostoru obeležja, dok su matrice konfuzije ukazale na uniformno raspoređene greške. Svi modeli pokazuju slične obrasce pogrešne klasifikacije, bez jasne prednosti bilo kog pristupa.

V. Zaključak

Cilj ovog rada bio je razvoj i evaluacija modela mašinskog učenja za predikciju rizika ponovne hospitalizacije pacijenata, kroz sistematičan proces koji obuhvata analizu podataka, pripremu, transformaciju i testiranje više algoritama.

Dobijeni rezultati pokazuju da svi primenjeni modeli ostvaruju slične i relativno niske performanse, sa vrednostima metrika u opsegu od 0.32 do 0.34. Iako je logistička regresija sa LDA transformacijom pokazala blagu prednost, razlike u odnosu na ostale modele su minimalne.

Ključni uvid ovog istraživanja jeste da ograničenje performansi ne proizilazi iz izbora algoritma, već iz same strukture podataka. Analiza je pokazala značajno preklapanje između klasa, kao i odsustvo jakih prediktivnih veza između ulaznih obeležja i ciljne promenljive. Kao posledica toga, modeli nisu u mogućnosti da uspostave jasne granice odlučivanja.

Ovaj rad potvrđuje važnu činjenicu u oblasti mašinskog učenja: kvalitet i informativnost podataka imaju presudan uticaj na uspešnost modela. Čak i primena naprednijih algoritama ne može nadomestiti nedostatak jasne strukture i separabilnosti u podacima.

Za budući rad, potencijalna unapređenja mogu uključivati korišćenje realnih kliničkih podataka, uvođenje novih, informativnijih obeležja, kao i primenu naprednijih metoda za ekstrakciju karakteristika. Bez poboljšanja kvaliteta podataka, značajan napredak u performansama modela nije očekivan.